

FinOps para arquitetos e devs

Como construir em Azure sem
explodir o orçamento

Gustavo Bigardi

CTO @ Clarus IT · Microsoft MVP





QUEM SOU

Gustavo Bigardi

CTO @ Clarus IT

Microsoft MVP · 7 vezes consecutivas

Semana passada, no Data Saturday Vitória: preview environments no Azure com Terraform. Esse caso volta hoje, com a lente de custo.

Ainda hoje, Aspire na prática e Github Copilot além do auto-complete.

github.com/gustavobigardi · about.me/gbbigardi



Toda decisão de
engenharia é uma
decisão de compra.

Erik Peterson, fundador da CloudZero

Quem aqui já levou susto com a fatura da
nuvem?

MVP

Cloud



O que vamos ver

01**A fatura chega depois**

Onde o custo se esconde

02**FinOps para quem constrói**

O que muda no dia a dia do time

03**Decisões que custam caro**

Seis cenários com preços oficiais

04**Brazil South ou EUA?**

Preço, latência e LGPD

05**Investir sem explodir**

O caso dos preview environments

06**Cultura e operação**

Guardrails, rituais e 2 demos

A fatura chega depois

A decisão é tomada na sprint 1. O custo aparece 30 dias depois, quando ninguém lembra por que o SKU é Premium ou por que o log está em Debug.

O tamanho do problema

29%

do gasto em nuvem é desperdício estimado; o primeiro aumento em cinco anos, puxado por IA

Flexera State of the Cloud 2026

65%

das empresas brasileiras não sabem onde gastam com nuvem

Radar da Nuvem 2026 (Samax/Talentum, apoio Magalu Cloud)

98%

dos times de FinOps já gerenciam gasto com IA

State of FinOps 2026

O que os times de FinOps mais pedem hoje: **orientação de arquitetura antes do deploy.**

State of FinOps 2026

Onde o custo se esconde

O QUE TODO MUNDO VÊ

VMs e bancos

App Service

Licenças

O QUE APARECE NA FATURA

Logs e telemetria

Tráfego entre regiões

Não-prod ligado 24/7

Recursos órfãos

Redundância sem requisito

Tokens de IA

Câmbio

Observabilidade custa em média **17% do gasto de compute** (Grafana Observability Survey 2025). Agentes de IA usam **5 a 30x mais tokens** que um chat comum (Gartner, 2026).

FinOps para quem constrói

FinOps não é planilha nem corte de gastos. É engenharia, finanças e negócio decidindo juntos, com dados, no momento certo.

O ciclo e os princípios

Inform

Visibilidade, alocação e custo por unidade



Optimize

Uso certo primeiro, taxa melhor depois



Operate

Governança, rituais e melhoria contínua

FinOps Foundation: princípios para devs

- Todo mundo é dono do que usa
- Valor de negócio guia a decisão técnica
- Custo variável é vantagem, não risco
- Engineering é persona central do framework

Well-Architected: pilar de custo

- Disciplina de custos
- Desenho com eficiência
- Otimização de uso
- Otimização de taxa
- Monitorar e otimizar sempre

Arquitetura é uma série de trade-offs

Velocidade

Entregar rápido

EXCESSO QUE CUSTA

Premium em tudo para não pensar em SKU agora

Simplicidade

Menos peças

EXCESSO QUE CUSTA

Um cluster AKS padrão até para três APIs pequenas

Governança

Controles e compliance

EXCESSO QUE CUSTA

Private Endpoint e firewall em todo ambiente

Eficiência

Custo por unidade de valor

EXCESSO QUE CUSTA

Otimizar cedo demais e perder o prazo

Não existe a escolha barata; existe a escolha **consciente**.

Decisões que custam caro

Seis cenários com preços oficiais do Azure. Cada um mostra a decisão, o custo escondido e a alternativa, em dólar e em real.

Como calculei

Preço de lista

Azure Retail Prices API, pay-as-you-go, coletado em 21/09/2026

Brazil South

Região base; East US 2 para comparação

730 h/mês

Mês cheio. Horário comercial = 12 h x 22 dias úteis

Dólar e real

PTAX de venda de 21/09/2026: R\$ 5,1117. Estimativa: a fatura usa a taxa do seu contrato

Só o recurso

Sem descontos de contrato, discos, load balancer, egress ou impostos, salvo quando indicado

Premissas no slide

Volume, horas e tamanho de cada cenário aparecem junto do número

Reproduza tudo: kit/calculos/cenarios.py

3 APIs pequenas não pedem um cluster

AKS Standard + 3x D4s v5
12 vCPU · 48 GiB · 24/7

US\$ 743 ≈ R\$ 3,8 mil

App Service 2x P0v3
2 vCPU · 8 GiB · 24/7

US\$ 162 ≈ R\$ 828

Container Apps (consumo)
escala a zero fora do horário

US\$ 47 ≈ R\$ 240

16x de diferença para o mesmo workload

O que pesa na decisão

- Capacidade que o workload usa de verdade
- Horas em que precisa estar de pé
- Tempo do time operando a plataforma
- Prime Video: -90% ao sair de serverless para um processo único (2023)
- TI da Microsoft: Functions -82% (Inside Track, 2022)

Dev não precisa ser cópia de prod

API Management em 4 ambientes


Premium em todos



US\$ 11.181
≈ R\$ 57,2 mil

SKU por ambiente

Developer · Standard v2 · Premium



US\$ 3.591
≈ R\$ 18,4 mil

4 VMs de dev (D4s v5)


Ligadas 24/7



US\$ 894
≈ R\$ 4,6 mil

Horário comercial

12 h x 22 dias úteis



US\$ 323
≈ R\$ 1,7 mil

–68%

–64%

Preço Dev/Test

TTL em ambiente efêmero

Auto-shutdown

Dados sintéticos

Observabilidade: log não é grátis

50 GB/dia em Analytics
Brazil South




US\$ 6.877 ≈ R\$ 35,2 mil

Mesmo volume
East US 2 (ver bloco 04)



US\$ 4.126 ≈ R\$ 21,1 mil

Otimizado
Brazil South



US\$ 1.454 ≈ R\$ 7,4 mil

-79%

O que mudou

- Nível Warning nos containers: -70% do volume
- Logs de container em Basic Logs
- Sampling de 25% no App Insights
- Commitment tier só a partir de 100 GB/dia
- Daily cap é cinto de segurança, não otimização

IA: o modelo certo para cada tarefa

gpt-6-astra




US\$ 15.000 ≈ R\$ 76,7 mil

gpt-5.6-sol



US\$ 6.000 ≈ R\$ 30,7 mil

gpt-5.6-terra



US\$ 3.240 ≈ R\$ 16,6 mil

gpt-5.6-luna



US\$ 324 ≈ R\$ 1,7 mil

Roteamento 80/20



US\$ 907 ≈ R\$ 4,6 mil

Roteamento + cache
70% da entrada em cache

US\$ 594 ≈ R\$ 3,0 mil

Alavancas

- Rotear por tarefa (model router)
- Cache de prompt: entrada em cache –90%
- Batch: –50% no que pode esperar 24 h
- Capacity: 4,2x mais barato com Phi-4 (Microsoft, 2025)
- Agentes usam 5 a 30x mais tokens (Gartner)

Rodada rápida: rede, escala e resiliência

REDE

Firewall por spoke

Premium x 4 spokes

US\$ 5.110
≈ R\$ 26,1 mil

Standard no hub

US\$ 912
≈ R\$ 4,7 mil

Centralize no hub. 60 Private Endpoints: ≈
US\$ 438/mês só de hora.

ESCALA

Cosmos DB, pico de 5k RU/s

Manual 24/7

US\$ 438
≈ R\$ 2,2 mil

Autoscale

US\$ 173
≈ R\$ 883

Serverless

US\$ 296
≈ R\$ 1,5 mil

Serverless não é sempre o mais barato e
tem teto de 5k RU/s por partição.

RESILIÊNCIA

Blob Hot, 10 TB

LRS

US\$ 334
≈ R\$ 1,7 mil

ZRS



US\$ 417
≈ R\$ 2,1 mil

GRS

US\$ 668
≈ R\$ 3,4 mil

Tráfego entre zonas é grátis. GRS do Brazil
South replica para o Texas.

Comprar melhor, por último

Pay-as-you-go		US\$ 223 ≈ R\$ 1,1 mil
Savings plan 1 ano		US\$ 142 ≈ R\$ 723
Savings plan 3 anos		US\$ 105 ≈ R\$ 538
Reserva 1 ano		US\$ 138 ≈ R\$ 705
Reserva 3 anos		US\$ 88 ≈ R\$ 451
Spot		US\$ 41 ≈ R\$ 211
PAYG em East US 2		US\$ 140 ≈ R\$ 716

Nessa ordem


- Tamanho certo primeiro; depois reserva e savings plan
- Desconto reduz a taxa, não o desperdício
- Novo: savings plan para bancos de dados
- Troca de reservas termina em 01/02/2027
- Spot: despejo com 30 s de aviso

Brazil South ou EUA?

Rodar nos EUA pode custar bem menos. Mas região é decisão de latência, de regulação e de contrato, não só de preço.

PREÇO UNITÁRIO x EAST US 2

Quanto o Brazil South custa a mais



Câmbio também é custo

- Preço de lista em USD
- No MCA, a fatura vem em BRL com a taxa fixada no mês
- Pagamento internacional pode ter IOF
- PTAX de 21/09/2026: R\$ 5,1117
- Modelos de IA Global Standard: mesmo preço

Latência, tráfego e disponibilidade

~118 ms

ida e volta entre Brazil South e East US / East US 2 (mediana, jul/2026)

- 139 ms até South Central US, o par regional

US\$ 0,16/GB

para sair do Brazil South para outro continente

- No sentido inverso: US\$ 0,05/GB
- Internet: US\$ 0,181/GB aqui; US\$ 0,087 nos EUA

IA

Global Standard processa em qualquer região, inclusive no brazilsouth

- Data Zone: só EUA, UE e APAC
- Processar só no Brasil: PTU regional, família gpt-4.1/4o

NÃO É ACONSELHAMENTO JURÍDICO

O que a lei diz

LGPD · dado pessoal

- Nuvem fora do Brasil é transferência internacional (art. 33)
- EUA: cláusulas-padrão da ANPD (Res. 19/2024), obrigatórias desde 23/08/2025
- UE/EEE: adequada desde jan/2026 (Res. 32/2026)

Setor financeiro · CMN 4.893

- Comunicar o BCB em até 10 dias, com as localidades
- Exterior: convênio com o supervisor (EUA têm) ou autorização prévia
- Acesso do BCB aos dados garantido em contrato

Setor público federal

- Dados hospedados no Brasil, com cópia atualizada aqui (IN GSI 5/2021)
- Classificada: só nuvem privada ou comunitária nacional (IN 8/2025)

Logs também contam

- IP, userId e e-mail são dado pessoal
- Workspace nos EUA também é transferência
- Pseudonimize na ingestão (DCR) ou mantenha no Brasil

Quando usar cada região

Brazil South

- Dado pessoal ou regulado em produção
- Latência sensível para usuário brasileiro
- Contrato ou cliente exige residência
- Setor público e financeiro com restrição

Antipadrão: app num país e banco no outro. São 118 ms por ida e volta e US\$ 0,16 por GB saindo do Brasil.

East US / East US 2

- Dev e teste com dados sintéticos
- Batch, analytics e IA com dados anonimizados
- Serviços e modelos que ainda não existem aqui
- Conteúdo público atrás de CDN

Pegadinha: GRS no Brazil South replica para South Central US. Use LRS/ZRS e a policy "Azure SQL DB should avoid using GRS backup".

Investir sem explodir

Semana passada, no Data Saturday Vitória: preview environments no Azure. Um investimento em qualidade que custa quase nada, porque foi desenhado para isso.

Compartilhe o caro, isole o barato

Compartilhado · 1 por assinatura

- App Service Plan B1
- Log Analytics
- Foundry + deployment do modelo (cota de TPM)

Isolado · 1 por tarefa, TTL de 7 dias

- Resource group e Web App
- Application Insights
- Projeto Foundry: agente, arquivos, vector store

10 previews por mês, 7 dias cada

B1 compartilhado
todos os previews

US\$ 12
≈ R\$ 63

Um B1 por preview

US\$ 29
≈ R\$ 146

Um P0v3 por preview
paridade com prod

US\$ 130
≈ R\$ 666

Resultado: zero revert de PR para liberar release, com custo marginal de quase só consumo.

O que descobri revisando o meu próprio setup

ACHADO

O janitor só reporta

CORREÇÃO

Destruir automaticamente o que venceu o TTL

ACHADO

O budget nunca foi criado

CORREÇÃO

Budget por RG de preview, com e-mail de verdade

ACHADO

Mudar o TTL não renova

CORREÇÃO

Renovação explícita do prazo

ACHADO

Tokens e telemetria sem dono

CORREÇÃO

Rateio por environment-key: tags e metadados


“Sucesso que ninguém questiona vira suposição.” The Frugal Architect, lei VII

Outro investimento que sai barato: evals de IA no CI com cache, escopo por diff e budget de tokens. Você paga pelo que mudou.

Cultura e operação

Eficiência técnica com responsabilidade financeira não nasce de planilha. Nasce de visibilidade, guardrails e rituais do time.

Sem dono e sem tag, não há otimização



FERRAMENTAS

Cost Management + FOCUS

FinOps toolkit

Azure Copilot

Resource Graph

Demo: caça ao desperdício

Queries do Resource Graph do kit

Discos, IPs, NICs e planos vazios

Sem tag e com TTL vencido

MVP

Co



Top 10 desperdícios em Azure

01 Discos gerenciados sem VM

02 IPs públicos sem uso

03 App Service Plans vazios

04 VMs paradas sem desalocar

05 Snapshots antigos (e em Premium)

06 Não-prod ligado 24/7

07 Log verboso em Analytics

08 SKU de prod em dev

09 GRS sem requisito de negócio

10 Compromisso ocioso (reserva, PTU, commitment tier)

01–05: a query do kit encontra · 06–10: decisões de arquitetura

Guardrails, não portões

Antes do deploy

- Custo como seção do ADR
- Estimativa no PR (ex.: Infracost)
- Policy: SKUs e regiões permitidos em não-prod

Durante

- Budget 90/100/110% e previsão
- Alerta de anomalia de custo
- TTL e auto-shutdown em não-prod

Depois

- Advisor e caça ao desperdício mensal
- Revisão de compromissos
- Custo por unidade no dashboard do time

Budget não desliga nada: ele avisa. Quem age é o time.

Demo: FinOps em linguagem natural

Azure Copilot na subscription da demo

Custo por serviço e previsão do mês

Recomendações e o “e se” de tokens

MVP

Co



O ritual de 30 minutos por mês

Agenda

- Custo x previsão do mês
- Top 5 variações e anomalias
- Caça ao desperdício com o kit
- Recomendações do Advisor
- Uma ação com dono e prazo

Custo por unidade

por pedido, cliente ou tenant

% do custo com dono

coberto por tags e alocação

Desperdício

encontrado x eliminado no mês

Compromissos

cobertura e uso de reservas e savings plans

O melhor momento
para economizar é
antes do deploy.

Custo é requisito não funcional: entra no
desenho, no PR e no ritual do time.

MVP

Co



Leve para casa

SEGUNDA-FEIRA

Tags obrigatórias, budget e alerta de anomalia em toda subscription

PRÓXIMA FEATURE

Seção de custo no ADR e estimativa no PR

TODO MÊS

30 minutos de caça ao desperdício com o kit



**[github.com/gustavobigardi/
finops-para-arquitetos-e-devs](https://github.com/gustavobigardi/finops-para-arquitetos-e-devs)
Queries, policies, budget, checklist e o script
dos números**

Siga MVP Conf nas redes sociais



LINKEDIN



@MVPCONF

Obrigado!

Gustavo Bigardi

github.com/gustavobigardi · about.me/gbbigardi